


Resumo

- Parte I: Busca e Planejamento 
- Parte II: Conhecimento e raciocínio
 - *Noções de incerteza*
 - *Cadeias de Markov*
 - *HMM*
 - *Redes Bayesianas*
 - *Raciocínio preciso*

Incerteza

- Situação geral:
 - **Variáveis observadas (evidência):** agente sabe algumas coisas do mundo (ex: sintomas, valor de sensores, etc.)
 - **Variáveis não observadas:** agente precisa raciocinar sobre outros aspectos (ex: onde o fantasma deve estar ou que doença o paciente tem, etc.)
 - **Modelo:** agente sabe algo sobre como as variáveis observadas se relacionam com as não observadas.
- **Raciocínio probabilístico** nos fornece um framework para lidar com nossas crenças (*beliefs*) e nosso conhecimento (*knowledge*).

0.11	0.11	0.11
0.11	0.11	0.11
0.11	0.11	0.11

0.17	0.10	0.10
0.09	0.17	0.10
<0.01	0.09	0.17

<0.01	<0.01	0.03
<0.01	0.05	0.05
<0.01	0.05	0.81

Variáveis Aleatórias

- Um aspecto do mundo sobre o qual pode existir incerteza
 - R = Está chovendo?
 - T = Quente ou frio?
 - D = Distância até o trabalho?
 - L = Onde está o fantasma?
- Domínios
 - R : {true, false} (usualmente, {+r, -r})
 - T : {hot, cold}
 - D : $[0, \infty)$
 - L : posições possíveis, {(0,0), (0,1), ...}

Distribuição de probabilidade

- Temperatura:

$P(T)$

T	P
hot	0.5
cold	0.5

- Tempo (clima):

$P(W)$

W	P
sun	0.6
rain	0.1
fog	0.3
meteor	0.0

Distribuição de probabilidade

- Variáveis aleatórias não observadas possuem distribuição

$P(T)$

T	P
hot	0.5
cold	0.5

$P(W)$

W	P
sun	0.6
rain	0.1
fog	0.3
meteor	0.0

Notação compacta:

$$\begin{aligned}P(\text{hot}) &= P(T = \text{hot}), \\P(\text{cold}) &= P(T = \text{cold}), \\P(\text{rain}) &= P(W = \text{rain}), \\&\dots\end{aligned}$$

- Uma distribuição é uma TABELA de probabilidade de valores
- Uma probabilidade (letra minúscula por convenção) é um valor

$$P(W = \text{rain}) = 0.1$$

$$\forall x \quad P(X = x) \geq 0$$

$$\sum_x P(X = x) = 1$$

Resumo sobre probabilidade


- Probabilidade condicional $P(x|y) = \frac{P(x, y)}{P(y)}$
- Regra do produto $P(x, y) = P(x|y)P(y)$
- Regra da cadeia
$$\begin{aligned} P(X_1, X_2, \dots, X_n) &= P(X_1)P(X_2|X_1)P(X_3|X_1, X_2) \dots \\ &= \prod_{i=1}^n P(X_i|X_1, \dots, X_{i-1}) \end{aligned}$$
- X, Y são **independentes** se e somente se: $\forall x, y : P(x, y) = P(x)P(y)$
 $X \perp\!\!\!\perp Y$
- X e Y são **condicionalmente independentes** dado Z se e somente se:
 $X \perp\!\!\!\perp Y | Z$
$$\begin{aligned} \forall x, y, z : P(x, y|z) &= P(x|z)P(y|z) \\ \forall x, y, z : P(x|z, y) &= P(x|z) \end{aligned}$$

Raciocinando no tempo (ou espaço)

- Frequentemente, queremos raciocinar sobre uma sequência de observações
 - Reconhecimento de fala
 - Reconhecimento de sentença em linguagem natural
 - Localização de robôs
 - Monitoramento médico
 - Etc...
- Necessidade de introduzir conceito de tempo (ou espaço) nos modelos

Modelos de Markov


- Estado = valor de X em um tempo t



$$P(X_1) \quad P(X_t|X_{t-1})$$

- **Probabilidade de transição (dinâmica):** especifica como o estado evolui no tempo
- Suposição de estacionaridade: probabilidades de transição são as mesmas para todo tempo t
- Semelhante à MDP, mas sem escolha de ações.

Distribuição conjunta de um Modelo de Markov



$$\begin{aligned} X_3 &\perp\!\!\!\perp X_1 \mid X_2 \\ X_4 &\perp\!\!\!\perp X_1, X_2 \mid X_3 \end{aligned}$$


- Distribuição conjunta:

$$P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2|X_1)P(X_3|X_2)P(X_4|X_3)$$

- De forma mais geral:

$$\begin{aligned} P(X_1, X_2, \dots, X_T) &= P(X_1)P(X_2|X_1)P(X_3|X_2) \dots P(X_T|X_{T-1}) \\ &= P(X_1) \prod_{t=2}^T P(X_t|X_{t-1}) \end{aligned}$$

Independências condicionais implícitas




- $X_3 \perp\!\!\!\perp X_1 \mid X_2$ e $X_4 \perp\!\!\!\perp X_1, X_2 \mid X_3$ é verdade!
- $X_1 \perp\!\!\!\perp X_3, X_4 \mid X_2$ também é verdade ?



Raciocínio pra frente

- Qual é a $P(X)$ em um tempo t ?



$P(x_1)$ = conhecida

$$\begin{aligned} P(x_t) &= \sum_{x_{t-1}} P(x_{t-1}, x_t) \\ &= \sum_{x_{t-1}} P(x_t \mid x_{t-1}) P(x_{t-1}) \end{aligned}$$


← Simulação pra frente (forward)

Raciocínio pra frente

$P(x_1)$ = conhecida

$$P(x_t) = \sum_{x_{t-1}} P(x_{t-1}, x_t) \\ = \sum_{x_{t-1}} P(x_t \mid x_{t-1}) P(x_{t-1})$$

x_{t-1}	x_t	$P(x_t \mid x_{t-1})$
sol	sol	0.9
sol	chuva	0.1
chuva	sol	0.3
chuva	chuva	0.7



1. Qual é a probabilidade de que no tempo $t=4$ esteja ensolarado considerando que agora ($t=1$) está ensolarado

$P(x_4=\text{sol} \mid x_1=\text{sol}) = 0.804$

Texto

$$P(x_4=\text{sol}) = \sum_{x_3} P(x_4=\text{sol} \mid x_3) P(x_3) \rightarrow P(x_4=\text{sol} \mid x_3=\text{sol}) \underbrace{P(x_3=\text{sol})}_{0.84} + P(x_4=\text{sol} \mid x_3=\text{chuva}) \underbrace{P(x_3=\text{chuva})}_{0.16}$$

$$\underbrace{P(x_3=\text{sol})}_{0.84} = \sum_{x_2} P(x_3=\text{sol} \mid x_2) P(x_2) \rightarrow P(x_3=\text{sol} \mid x_2=\text{sol}) \underbrace{P(x_2=\text{sol})}_{0.9} + P(x_3=\text{sol} \mid x_2=\text{chuva}) \underbrace{P(x_2=\text{chuva})}_{0.1}$$

$$\underbrace{P(x_3=\text{chuva})}_{0.16} = \sum_{x_2} P(x_3=\text{chuva} \mid x_2) P(x_2) \rightarrow P(x_3=\text{chuva} \mid x_2=\text{sol}) \underbrace{P(x_2=\text{sol})}_{0.9} + P(x_3=\text{chuva} \mid x_2=\text{chuva}) \underbrace{P(x_2=\text{chuva})}_{0.1}$$

$$\underbrace{P(x_2=\text{sol})}_{0.9} = \sum_{x_1} P(x_2=\text{sol} \mid x_1) P(x_1) \rightarrow P(x_2=\text{sol} \mid x_1=\text{sol}) \underbrace{P(x_1=\text{sol})}_{1}$$

$$\underbrace{P(x_2=\text{chuva})}_{0.1} = \sum_{x_1} P(x_2=\text{chuva} \mid x_1) P(x_1) \rightarrow P(x_2=\text{chuva} \mid x_1=\text{sol}) \underbrace{P(x_1=\text{sol})}_{1}$$


$$P(x_1=\text{sol}) = \text{conhecida}$$

Raciocínio pra frente

$P(x_1)$ = conhecida

$$P(x_t) = \sum_{x_{t-1}} P(x_{t-1}, x_t) \\ = \sum_{x_{t-1}} P(x_t \mid x_{t-1}) P(x_{t-1})$$

x_{t-1}	x_t	$P(x_t \mid x_{t-1})$
sol	sol	0.9
sol	chuva	0.1
chuva	sol	0.3
chuva	chuva	0.7



2. Qual é a probabilidade de que no tempo $t=4$ esteja ensolarado considerando que agora ($t=1$) está chovendo

$P(x_4=\text{sol} \mid x_1=\text{chuva}) = 0.588$

$$P(x_4=\text{sol}) = \sum_{x_3} P(x_4=\text{sol} \mid x_3) P(x_3) \rightarrow P(x_4=\text{sol} \mid x_3=\text{sol}) \underset{0.9}{P(x_3=\text{sol})} + P(x_4=\text{sol} \mid x_3=\text{chuva}) \underset{0.52}{P(x_3=\text{chuva})}$$

$$P(x_3=\text{sol}) = \sum_{x_2} P(x_3=\text{sol} \mid x_2) P(x_2) \rightarrow P(x_3=\text{sol} \mid x_2=\text{sol}) \underset{0.9}{P(x_2=\text{sol})} + P(x_3=\text{sol} \mid x_2=\text{chuva}) \underset{0.7}{P(x_2=\text{chuva})}$$

$$P(x_3=\text{chuva}) = \sum_{x_2} P(x_3=\text{chuva} \mid x_2) P(x_2) \rightarrow P(x_3=\text{chuva} \mid x_2=\text{sol}) \underset{0.1}{P(x_2=\text{sol})} + P(x_3=\text{chuva} \mid x_2=\text{chuva}) \underset{0.7}{P(x_2=\text{chuva})}$$

$$P(x_2=\text{sol}) = \sum_{x_1} P(x_2=\text{sol} \mid x_1) P(x_1) \rightarrow P(x_2=\text{sol} \mid x_1=\text{chuva}) \underset{0.3}{P(x_1=\text{chuva})}$$

$$P(x_2=\text{chuva}) = \sum_{x_1} P(x_2=\text{chuva} \mid x_1) P(x_1) \rightarrow P(x_2=\text{chuva} \mid x_1=\text{chuva}) \underset{0.7}{P(x_1=\text{chuva})}$$

$P(x_1=\text{chuva})$ = conhecida

Distribuição Estacionária P_∞

- Para a maioria das cadeias:
 - Influência da distribuição inicial diminui com o passar do tempo
 - A distribuição final é **então independente da inicial** e é chamada de **Estacionária**

$$P_\infty(X) = P_{\infty+1}(X) = \sum_x P(X|x)P_\infty(x)$$

Distribuição Estacionária

3. Qual a chance de estar ensolarado em $t = \infty$

$$P_{\infty}(X) = P_{\infty+1}(X) = \sum_x P(X|x)P_{\infty}(x)$$

$P(x_{\infty} = \text{sol}) = ?$

X_{t-1}	X_t	$P(X_t X_{t-1})$
sol	sol	0.9
sol	chuva	0.1
chuva	sol	0.3
chuva	chuva	0.7

$$P(x_{\infty} = \text{sol}) = P(\text{sol}|\text{sol})P(x_{\infty} = \text{sol}) + P(\text{sol}|\text{chuva})P(x_{\infty} = \text{chuva})$$

$$P(x_{\infty} = \text{sol}) = 0.9 P(x_{\infty} = \text{sol}) + 0.3 P(x_{\infty} = \text{chuva})$$

$$P(x_{\infty} = \text{sol}) - 0.9 P(x_{\infty} = \text{sol}) = 0.3 P(x_{\infty} = \text{chuva})$$

$$0.1 P(x_{\infty} = \text{sol}) = 0.3 P(x_{\infty} = \text{chuva})$$

$$P(x_{\infty} = \text{sol}) = 3 P(x_{\infty} = \text{chuva})$$

$$\text{Sabendo-se que: } P(x_{\infty} = \text{sol}) + P(x_{\infty} = \text{chuva}) = 1$$



$$P(x_{\infty} = \text{sol}) = 3 (1 - P(x_{\infty} = \text{sol}))$$

$$4 P(x_{\infty} = \text{sol}) = 3$$

$$P(x_{\infty} = \text{sol}) = 0.75$$

$$P(x_{\infty} = \text{chuva}) = 0.25$$

Aplicação da distribuição estacionária:

PageRank™


- Algoritmo que mede a **importância de uma página** contabilizando a quantidade e qualidade de **links que apontam para ela**.
- **Simula a navegação aleatória** de alguém na Web de modo a aferir a **importância de cada página no infinito**
- O processo do PageRank foi patenteado pela Universidade de Stanford.
- Google detém os direitos de licença exclusivos: cedeu 1,8 milhão de ações (em 2005, U\$336 milhões)

Algoritmo do PageRank™

- $\sum_{X=\{A,B,C,D,\dots\}} PageRank(X) = 1$
- Iteração 1:
 - $PageRank(X) = 1/N$ ($N = \#páginas$)

- Iteração 2:

- $PageRank(A) = \frac{PageRank(B)}{2} + \frac{PageRank(C)}{1} + \frac{PageRank(D)}{3}$
- $PageRank(B) = \dots$, $PageRank(C) = \dots$, $PageRank(D) = \dots$
- $PageRank(u) = \sum_{v \in B_u} \frac{PageRank(v)}{L(v)}$




$L(v)$ = hiperlinks da página v


B_u = conjunto de todas as páginas que referenciam u

Algoritmo do PageRankTM

- Problemas: *páginas sem ligações* e *ciclos*



...drenagem do PageRank para fora da rede.

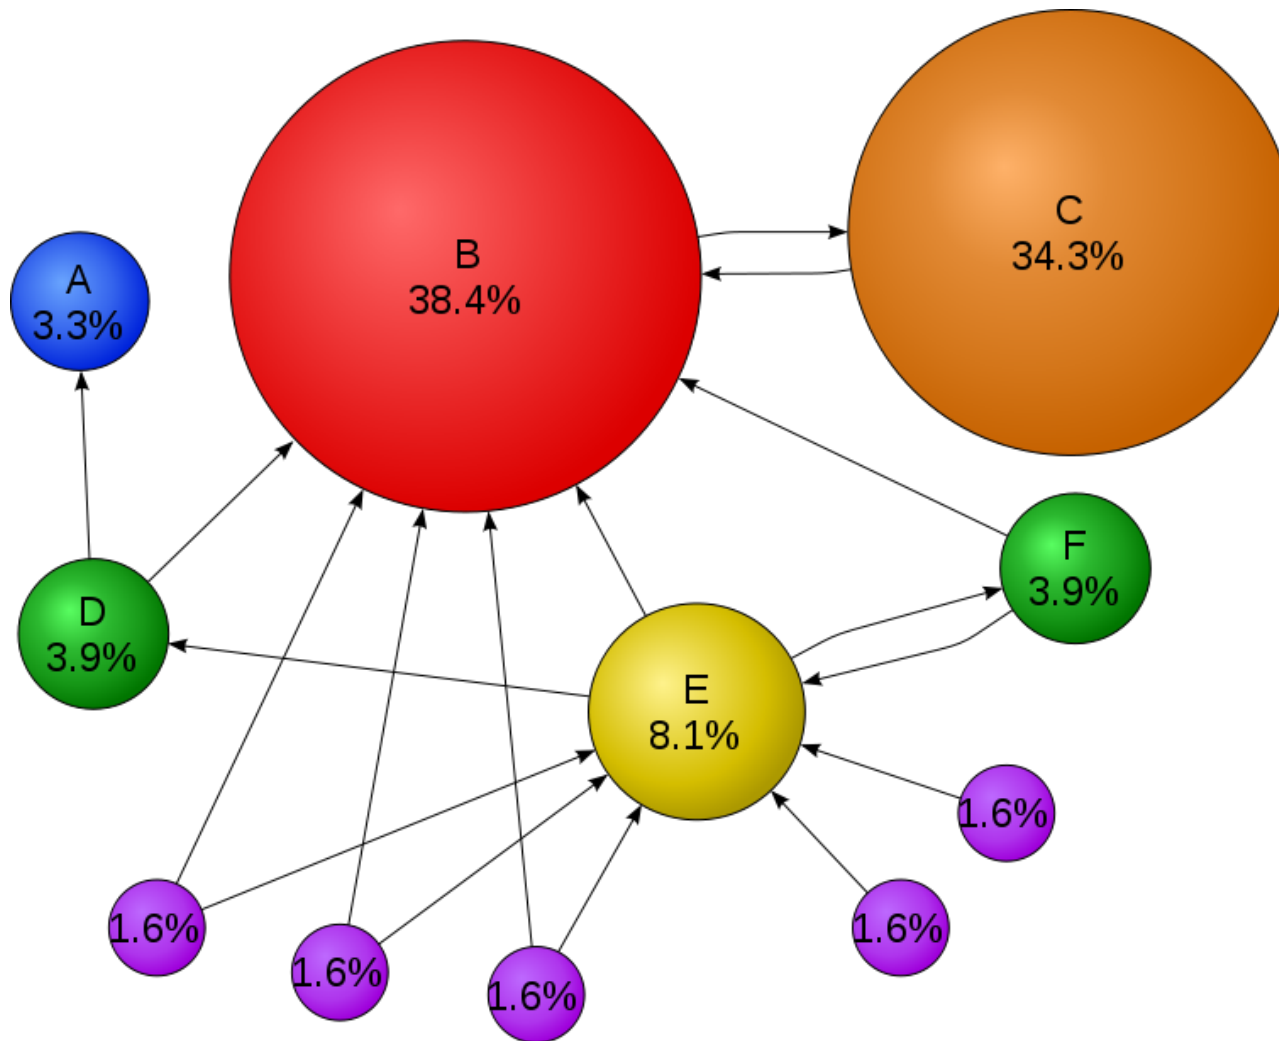


PageRank fica "preso" no ciclo infinito ...
....e valores não convergem para valores estacionários.

Algoritmo do PageRank™

- A teoria de PageRank considera que um usuário imaginário que siga os hiperlinks entre as páginas aleatoriamente, acabará por se aborrecer e parar de seguir.
- A probabilidade, em cada passo, de o utilizador continuar a seguir os hiperlinks é o **fator de amortecimento** d
- $$PageRank(A) = \frac{1-d}{N} + d \left(\frac{PageRank(B)}{2} + \frac{PageRank(C)}{1} + \frac{PageRank(D)}{3} \right)$$
 - Com $d = 1$, peso completo à estrutura de hiperlinks
 - Com $d = 0$, aleatoriedade pura na navegação

Estacionaridade do PageRank™



- No **infinito**, a **probabilidade** de se atingir qualquer página é **estacionária**
→ modelado via *Cadeia de Markov*
- Se um usuário começar numa página aleatória com uma **probabilidade de 85% (fator de amortecimento) de escolher um hiperlink aleatório** dessa página e uma **probabilidade de 15% de saltar para uma página qualquer** de toda a rede,
→ esse usuário irá chegar ao nó E em 8,1% das vezes.
- Se fator = 100% ?
→ qualquer utilizador acabaria nos nós A, B, ou C.