



# Modelagem da marcha





- Os ângulos das articulações de uma pessoa são variáveis aleatórias que mudam com o tempo
- Cadeias de Markov podem ser usadas para:
  - prever esses valores em uma sequência
  - Reconhecer uma pessoa pela sua marcha

# Navegação de robôs



# Cadeias de Markov

- O estado é diretamente visível ao observador. Os únicos parâmetros usados são as probabilidades de transição de estado.



# Cadeias de Markov

- Limitação: em muitas situações, esses estados não são visíveis e precisam ser estimados a partir de observações/evidências: atualização das crenças do agente


→ modelagem via **Hidden Markov Models (HMM)**

# HMM

- Hidden Markov Models (HMMs)
  - Cardeia de Markov sobre estados X
  - Observações/evidências a cada passo de tempo

Condições iniciais

$$P(X_0)$$




$$P(E_t | X_t)$$

Modelo de transição  
(dinâmica)

Modelo sensor

# Distribuição conjunta de um HMM



- Distribuição conjunta:

$$P(X_1, E_1, X_2, E_2, X_3, E_3) = P(X_1)P(E_1|X_1)P(X_2|X_1)P(E_2|X_2)P(X_3|X_2)P(E_3|X_3)$$

- Generalização:

$$P(X_1, E_1, \dots, X_T, E_T) = P(X_1)P(E_1|X_1) \prod_{t=2}^T P(X_t|X_{t-1})P(E_t|X_t)$$

- Implicação da independência condicional


$$E_1 \perp\!\!\!\perp X_2, E_2, X_3, E_3 \mid X_1$$

# Automatic Speech Recognition (ASR)

Sinal de fala




Segmentação  
em quadros



Características


“tomato”  $\Rightarrow$  [t ow m ey t ow] , [t ow m aa t ow]

Modelo de transição  
(dinâmica)



# Automatic Speech Recognition (ASR)


## Modelo de transição



# NER – Named Entity Recognition

Reconhecer entidades nomeadas é uma atividade da área de **Extração de Informação** que consiste em extrair informações importantes de um texto e rotulá-las adequadamente.

Em Brasília, o procurador-geral da República, Rodrigo Janot, pediu ao Supremo Tribunal Federal (STF) a prisão do ex-presidente José Sarney (PMDB-AP), do presidente do Senado, Renan Calheiros (PMDB-AL), e do senador Romero Jucá (PMDB-RR), por tentarem interferir nas investigações da Operação Lava Jato. Segundo publicou o jornal O Globo nesta terça-feira (7), o ministro do STF Teori Zavascki já teria recebido o pedido de prisão há uma semana.



# POS Tagging

Original Sentence: One such analysis identified one set of articles showing that dietary fish oils lead to certain blood and vascular changes, and a second set containing evidence that similar changes might benefit patients with Raynaud's syndrome.



CD	JJ	NN	VBD	CD	NN	IN	NNS	VBG	IN	JJ	NN	NNS	VBP	TO	JJ	NN	CC	
1	One	such	analysis	identified	one	set	of	articles	showing	that	dietary	fish	oils	lead	to	certain	blood	and
	JJ	NNS	,	CC	DT	JJ	NN	VBG	NN	IN	JJ	NNS	MD	VB	NNS	NN	CC	
	vascular	changes,	and	a	second	set	containing	evidence	that	similar	changes	might	benefit	patients	IN	NNP	POS	NN

with Raynaud 's syndrome.

# Tarefas comuns à HMM


- Filtering/monitoring
- Prediction
- Smoothing
- Most likely explanation

# Filtering/monitoring (estimativa de estado)

- Qual o estado de crença (**belief state**) atual, dado o histórico de observações/evidências ?


$P(X_i | E_0, E_1, \dots, E_i) ?$

$P(X_t | e_{1:t})$




# Filtering/monitoring

- Crença inicial




# Filtering/monitoring

- Estado de crença após mover para esquerda




# Filtering/monitoring

- Estado de crença após mover 2 vezes para esquerda



# Filtering/monitoring

$$P(X_t | e_{1:t}) = P(X_t | e_{1:t-1}, e_t)$$



# Filtering/monitoring

$$P(X_t | e_{1:t}) = \text{FORWARD}\left(P(X_{t-1} | e_{1:t-1}), e_t\right)$$
$$= \frac{P(e_t | X_t) P(X_t | e_{1:t-1})}{P(e_t | e_{1:t-1})} \quad (\text{Bayes' Rule})$$

Algoritmo **FORWARD**

$$= \frac{P(e_t | X_t) P(X_t | e_{1:t-1})}{P(e_t | e_{1:t-1})}$$
$$= \frac{P(e_t | X_t) \sum_{x_{t-1}} P(X_t | x_{t-1}, e_{1:t-1}) P(x_{t-1} | e_{1:t-1})}{P(e_t | e_{1:t-1})}$$
$$= \frac{P(e_t | X_t) \sum_{x_{t-1}} P(X_t | x_{t-1}) P(x_{t-1} | e_{1:t-1})}{P(e_t | e_{1:t-1})} \quad (\text{Markov})$$
$$= \propto \frac{P(e_t | X_t) \sum_{x_{t-1}} P(X_t | x_{t-1}) P(x_{t-1} | e_{1:t-1})}{\sum_{x_t} P(e_t | x_t) \sum_{x_{t-1}} P(x_t | x_{t-1}) P(x_{t-1} | e_{1:t-1})}$$

# Filtering/monitoring

- Algoritmo recursivo para estimar crença atual

$$P(X_{t+1} | e_{1:t+1}) = f(e_{t+1}, P(X_t | e_{1:t}))$$

Crença atual é projetada *forward* de  $t \rightarrow t+1$  e, então, é atualizada usando a nova evidência  $e_{t+1}$

$$P(X_{t+1} | e_{1:t+1}) = P(X_{t+1} | e_{1:t}, e_{t+1})$$

$$= \alpha P(e_{t+1} | X_{1:t}, e_{1:t}) P(X_{t+1} | e_{1:t}) \quad (\text{Bayes rule})$$

Objetivo é reorganizar p/  
**modelo sensor fornecido**

$$= \alpha P(e_{t+1} | X_{1:t}) P(X_{t+1} | e_{1:t}) \quad (\text{Cobertura de Markov})$$

Atualiza a previsão  
com nova evidência

Representa previsão do próximo  
estado dadas evidências anteriores


- Obtemos previsão no próximo estado condicionando ao estado corrente  $X_t$

$$P(X_{t+1} | e_{1:t+1}) = \alpha P(e_{t+1} | X_{1:t}) \sum_{x_t} P(X_{t+1} | x_t, e_{1:t}) P(x_t | e_{1:t})$$


$$P(X_{t+1} | e_{1:t+1}) = \alpha P(e_{t+1} | X_{1:t}) \sum_{x_t} P(X_{t+1} | x_t) P(x_t | e_{1:t}) \quad (\text{Markov})$$

**Modelo de transição fornecido**

# Exemplo do guarda-chuva



# Exemplo do guarda-chuva



$$X_t = \{\text{rain , no rain}\}$$


$$E_t = \{\text{umbrella , no umbrella}\}$$

R <sub>t</sub>	R <sub>t+1</sub>	P(R <sub>t+1</sub>  R <sub>t</sub> )
+r	+r	0.7
+r	-r	0.3
-r	+r	0.3
-r	-r	0.7

R <sub>t</sub>	U <sub>t</sub>	P(U <sub>t</sub>  R <sub>t</sub> )
+r	+u	0.9
+r	-u	0.1
-r	+u	0.2
-r	-u	0.8

## Exemplo do guarda-chuva

True  
False



$R_t$	$R_{t+1}$	$P(R_{t+1} R_t)$
+r	+r	0.7
+r	-r	0.3
-r	+r	0.3
-r	-r	0.7

$R_t$	$U_t$	$P(U_t R_t)$
+r	+u	0.9
+r	-u	0.1
-r	+u	0.2
-r	-u	0.8

$$\langle 0.9, 0.2 \rangle \quad \langle 0.7, 0.3 \rangle \times 0.5 + \langle 0.3, 0.7 \rangle \times 0.5 \quad \langle 0.5, 0.5 \rangle$$

$$P(R_1|u_1) = \alpha P(u_1|R_1) \sum_{r_0} P(R_1|r_0)P(r_0)$$

?????????????

$$\langle 0.9, 0.2 \rangle \quad \langle 0.7, 0.3 \rangle \times ??? + \langle 0.3, 0.7 \rangle \times ???$$

$$P(R_2|u_1, u_2) = \alpha P(u_2|R_2) \sum_{r_1} P(R_2|r_1) P(r_1|u_1)$$

$$= \langle 0.818, 0.182 \rangle$$

$$= \langle 0.883, 0.117 \rangle$$

$$P(X_{t+1}|e_{1:t+1}) = \alpha P(e_{t+1}|X_{1:t}) \sum_{x_t} P(X_{t+1}|x_t) P(x_t|e_{1:t})$$

# Questão: rastreando animais

- Objetivo: rastrear a posição de um animal em um ambiente triangular através do som emitido
- Cenário: 03 microfones, cada um localizado em um vértice do ambiente. Os microfones produzem informação binária ruidosa a cada passo de tempo. O animal está perto de um dos microfones ou próximo ao meio do triângulo.
- Estados do mundo:  $\{m, c_1, c_2, c_3\}$
- Efeitos (observações):  $\{\text{mic}_1, \text{mic}_2, \text{mic}_3\}$
- Modelo de transição:  $P(c_i|c_i)=0.8, P(m|c_i)=0.1, P(c_{j \neq i}|c_i)=0.05, P(m|m)=0.7, P(c_i|m)=0.1$
- Modelo sensor:  $P(\text{mic}_i|c_i)=0.6, P(\text{mic}_{j \neq i}|c_i)=0.1, P(\text{mic}_i|m)=0.4$
- Inicialmente:  $P(m)=P(c_1)=P(c_2)=P(c_3)$

# Questão: rastreando animais


- A tabela abaixo mostra as crenças do sistema de rastreamento após as observações do tempo  $t=2$ . Mostre os cálculos para se chegar nestes valores.

Time	Observation			Posterior State Distribution			
	Mic#1	Mic#2	Mic#3	$P(m)$	$P(c_1)$	$P(c_2)$	$P(c_3)$
0	-	-	-	0.25	0.25	0.25	0.25
1	0	1	1	0.46	0.019	0.26	0.26
2	1	0	1	0.64	0.084	0.019	0.26

# Prediction

- Qual a probabilidade de ocorrência de uma observação em um tempo **futuro**, dado o histórico de observações/evidências até o tempo presente?

$$P(E_{t+1:T} \mid e_{1:t})$$




Algoritmo **BACKWARD**

# Smoothing

- Qual o estado de crença (belief) em um tempo  $t=k$ , dado o histórico de observações (evidências) até o tempo presente?

$$P(X_k \mid e_{1:t})$$




Algoritmo **FORWARD-BACKWARD**

# Most likely explanation


- Qual a sequência de estados escondidos que maximiza a crença conjunta considerando todas as evidências ?

$$\arg \max_{X_{0:t}} P(X_{0:t} \mid e_{1:t})$$



# Most likely explanation

- Suponha que as observações são [*true*, *true*, *false*, *true*, *true*]. Qual a **sequência** de condições do tempo que melhor explica essas evidências?



# Most likely explanation

$$\max_{x_1 \dots x_t} P(x_1, \dots, x_t, X_{t+1} \mid e_{1:t+1}) = \\ \frac{1}{z} P(e_{t+1} \mid X_{t+1}) \max_{x_t} \left( P(X_{t+1} \mid x_t) \max_{x_1 \dots x_{t-1}} P(x_1, \dots, x_{t-1}, x_t \mid e_{1:t}) \right)$$

# Algoritmo Viterbi

Um dos mais importantes conceitos matemáticos do século 20.  
Mecanismo que permite separar informação relevante do ruído de background.

*Contribuições relacionadas:*

Wi-Fi,

Sinal 3G,

Comunicação digital via satélite,

Reconhecimento de fala,

Sequenciamento de DNA,

etc.

Andrew J. Viterbi

